

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH**



**BÁO CÁO ĐỒ ÁN CUỐI KỲ
MÔN HỌC: CS431 - HỌC SÂU & CÁC KỸ THUẬT ỨNG DỤNG
ĐỀ TÀI: XÂY DỰNG HỆ THỐNG GIẢI TOÁN TIẾNG VIỆT ỨNG
DỤNG AI REASONING**

Lớp: CS431.P11

Giảng viên hướng dẫn: TS. Nguyễn Vinh Tiệp

Sinh viên thực hiện:

- | | |
|----------------------|----------|
| 1. Bùi Nhật Anh Khôi | 23520761 |
| 2. Định Lê Bình An | 23520004 |
| 3. Phạm Quốc Nam | 23520984 |

TP. Hồ Chí Minh, ngày 20 tháng 11 năm 2025

MỤC LỤC

1. Giới thiệu bài toán.....	3
2. Bộ dữ liệu (Dataset).....	4
2.1. Tên bộ dữ liệu.....	4
2.2. Lý do chọn dữ liệu.....	4
2.3. Thông số dữ liệu.....	4
2.3.1. Bộ dữ liệu gốc (Vietnamese-395k-meta-math).....	4
2.3.2. Bộ dữ liệu Agentic.....	6
3. Hướng tiếp cận và Quy trình xử lý.....	7
3.1. Tiền xử lý dữ liệu.....	7
3.1.1. Khởi tạo và chuẩn bị dữ liệu.....	7
3.1.2. Phân tích và Làm sạch Dữ liệu.....	7
3.1.3. Tiền xử lý cho mô hình Chat.....	8
3.1.4. Định nghĩa Tools.....	8
3.1.5. ToolUseAgent.....	8
3.1.6. Cấu hình Huấn luyện.....	9
3.2. Huấn luyện, đánh giá và tối ưu mô hình (Model Training, Evaluation and Optimization).....	9
3.2.1. Quy trình tổng quan.....	9
3.2.2. Các phương pháp tiếp cận mô hình.....	10
3.2.3. Đánh giá mô hình.....	11
4. Thực nghiệm.....	11
4.1. Phân chia tập dữ liệu.....	11
4.2. Kết quả đánh giá.....	11
4.3. Phân tích.....	12
4.3.1 Tại sao mô hình Llama 3.2 1B có Reasoning Rate cao nhất nhưng lại có Exact Match và Numerical Accuracy thấp hơn mô hình Qwen 2.5 1.5B (CoT).....	12
4.3.2 Tại sao mô hình Qwen Agent không cho ra kết quả tốt hơn Qwen 2.5 1.5B (CoT).....	12
4.4 Demo.....	13
5. Tham khảo.....	13

DANH MỤC HÌNH ẢNH

Hình 1.1: Các dạng bài toán.....	4
Hình 1.2: Độ dài câu truy vấn.....	5
Hình 1.3: Độ dài câu phản hồi.....	5
Hình 1.4: Ví dụ quá trình tạo Agent data tool.....	6
Hình 1.5: Tokenizer pipeline.....	7
Hình 1.6: Demo.....	12

DANH MỤC BẢNG

Bảng 1.1: Kết quả thực nghiệm.....	12
---	----

1. Giới thiệu bài toán

Các mô hình ngôn ngữ lớn (LLM) hiện nay có khả năng suy luận, phân tích ngữ cảnh và xử lý những bài toán có độ phức tạp cao vượt trội so với các mô hình truyền thống. Tuy nhiên, để đạt được mức hiệu quả này, chúng thường phải sở hữu số lượng tham số cực lớn, đôi khi lên đến hàng chục hoặc hàng trăm tỷ. Quy mô tham số khổng lồ như vậy dẫn đến chi phí vận hành, triển khai và tối ưu hóa mô hình trở nên rất cao, đồng thời đòi hỏi hệ thống hạ tầng tính toán mạnh mẽ, bao gồm GPU hiệu năng cao, bộ nhớ lớn và kiến trúc phân tán ổn định.

Mục tiêu của đề án là xây dựng một hệ thống AI có khả năng suy luận và giải quyết hiệu quả các bài toán toán học từ cấp tiểu học đến trung học hoàn toàn bằng tiếng Việt với độ chính xác cao gọn nhẹ hơn nhưng hiệu quả, phù hợp với điều kiện triển khai thực tế. Hệ thống được phát triển theo hướng agentic (tác tử thông minh), trong đó mô hình không chỉ xử lý ngôn ngữ tự nhiên mà còn biết chủ động lựa chọn, phối hợp và sử dụng các công cụ tính toán một cách chính xác. Nhờ khả năng kết hợp giữa tư duy ngôn ngữ và thao tác công cụ, hệ thống hướng tới việc tạo ra lời giải mạch lạc, logic và đáng tin cậy, đáp ứng tốt nhu cầu học tập và hỗ trợ giáo dục trong thực tế.

2. Bộ dữ liệu (Dataset)

2.1. Tên bộ dữ liệu

- Vietnamese-395k-meta-math: [Link dataset](#)
- EleutherAI/hendrycks_math: [Link dataset](#)

2.2. Lý do chọn dữ liệu

Bộ dữ liệu được sử dụng trong đề án sở hữu nhiều ưu điểm nổi bật, đáp ứng tốt nhu cầu xây dựng một hệ thống AI có khả năng suy luận và giải toán bằng tiếng Việt:

Quy mô lớn và giàu thông tin: Với khoảng 395.000 cặp câu hỏi – lời giải, đây là một trong những bộ dữ liệu toán học có kích thước lớn nhất hiện nay dành cho tiếng Việt. Quy mô này giúp mô hình học được nhiều dạng bài toán và đa dạng cách trình bày lời giải.

Đa dạng về chủ đề và cấp độ kiến thức: Dữ liệu được tổng hợp từ hai nguồn uy tín là GSM8K (tập trung vào toán tư duy cấp tiểu học) và MATH (bao quát các chủ đề Toán trung học như đại số, hình học, số học, giải tích...). Nhờ vậy, bộ dữ liệu phản ánh đầy đủ phổ bài toán từ cơ bản đến nâng cao.


Hỗ trợ song ngữ: Các cặp dữ liệu được xây dựng song song giữa tiếng Anh và tiếng Việt, tạo điều kiện thuận lợi cho việc fine-tune mô hình theo hướng vừa hiểu ngôn ngữ tự nhiên vừa thực hiện suy luận chính xác.

2.3. Thông số dữ liệu


2.3.1. Bộ dữ liệu gốc (Vietnamese-395k-meta-math)

Đây là bộ dữ liệu nền tảng được sử dụng để cung cấp kiến thức toán học và khả năng suy luận ngôn ngữ cho mô hình.


- **Số mẫu:** 395.000 mẫu
- **Số đặc trưng:** 2 cột chính (query_vi, response_vi)
- **Loại bài toán:** Hỏi đáp toán học (Mathematical Question Answering) và Suy luận chuỗi (Chain-of-Thought).
- **Các đặc trưng trong bộ dữ liệu:**
 - **Query_vi:** đầu vào của bài toán, chứa nội dung đề bài bằng tiếng Việt. Dữ liệu này giúp mô hình rèn luyện khả năng đọc hiểu và phân tích yêu cầu.
 - **Response_vi:** chuỗi suy luận chi tiết (Chain-of-Thought) dẫn đến đáp án cuối cùng



Hình 1.1: Các dạng bài toán



Hình 1.2: Độ dài câu truy vấn



Hình 1.3: Độ dài câu phản hồi

2.3.2. Bộ dữ liệu Agentic

Đây là bộ dữ liệu được nhóm sinh ra từ quy trình `data_gen`, chuyển đổi từ dạng văn bản thuần túy sang dạng hội thoại có gọi công cụ.

- **Số mẫu:** 1500 mẫu
- **Cấu trúc:** Định dạng JSON danh sách hội thoại (List of Messages)

Quá trình tạo Agent data tool:

- Lấy các bài toán và lời giải bằng Tiếng Anh từ bộ dữ liệu gốc (EleutherAI/hendrycks_math).
- Sử dụng một AI như Gemini 2.5 Flash tạo dữ liệu.
- Ra lệnh cho Gemini: "Hãy đóng vai là một Agent. Nhìn vào lời giải, tại bước cần tính toán (ví dụ $25 \div 8$), hãy tạo lệnh gọi. Sau đó, dịch toàn bộ sang Tiếng Việt."

```
[
  {
    "role": "system",
    "content": "Hãy trả lời câu hỏi nhanh."
  },
  {
    "role": "user",
    "content": "Đối với hàm số  $y = \frac{x+2}{5x-7}$ , tiệm cận đứng tồn tại tại giá trị  $x$  nào?"
  },
  {
    "role": "assistant",
    "content": "Tiệm cận đứng xảy ra khi mẫu số bằng 0. Tôi sẽ giải phương trình mẫu số bằng 0.",
    "tool_calls": [
      {
        "function": {
          "name": "solve_equation",
          "arguments": {
            "equation": "5x-7=0",
            "variable": "x"
          }
        }
      }
    ]
  },
  {
    "role": "tool",
    "content": "7/5"
  },
  {
    "role": "assistant",
    "content": "Tiệm cận đứng tồn tại tại  $x = \frac{7}{5}$ ."
  }
]
```

Hình 1.4: Ví dụ quá trình tạo Agent data tool

3. Hướng tiếp cận và Quy trình xử lý

3.1. Tiền xử lý dữ liệu

3.1.1. Khởi tạo và chuẩn bị dữ liệu

- **Thư viện:** sử dụng các thư viện quan trọng như transformers (dùng mô hình), datasets (xử lý dữ liệu), numexpr (tính toán), wikipedia (tra cứu), và langchain (hỗ trợ xây dựng ứng dụng LLM).


3.1.2. Phân tích và Làm sạch Dữ liệu

Trước khi huấn luyện, nhóm thực hiện các bước kiểm tra chất lượng dữ liệu kỹ lưỡng:

- **Trực quan hóa:** Vẽ biểu đồ phân phối độ dài của câu hỏi (query) và câu trả lời (response). Điều này giúp phát hiện các mẫu dữ liệu bất thường.
- **Làm sạch:**
 - Xóa các dòng có giá trị rỗng (missing values).
 - Loại bỏ các điểm ngoại lai (outliers).
 - Xóa các dữ liệu trùng lặp (duplicates) để tránh mô hình học vẹt.

3.1.3. Tiền xử lý cho mô hình Chat

- **Chat Template:** Dữ liệu được chuyển đổi sang định dạng hội thoại chuẩn của Qwen:
 - System: "Please reason step by step..." (Hướng dẫn hệ thống).
 - User: Câu hỏi toán học.
 - Assistant: Lời giải chi tiết.
- **Tokenization:** Sử dụng tokenizer của Qwen/Qwen2.5-Math-1.5B để mã hóa văn bản thành số, sẵn sàng đưa vào mô hình.



Hình 1.5: Tokenizer pipeline

3.1.4. Định nghĩa Tools

- **Calculator:** Sử dụng thư viện numexpr để thực hiện các phép tính số học chính xác tuyệt đối.
- **WikipediaRetriever:** Công cụ để tra cứu kiến thức bên ngoài.
- **Schema:** Các công cụ này được mô tả dưới dạng JSON schema để mô hình có thể hiểu cách sử dụng (tên hàm, tham số đầu vào).

3.1.5. ToolUseAgent

- **invoke_tool:** Hàm này nhận lệnh từ mô hình (ví dụ: chuỗi Calculator[123 * 45]), thực thi nó và trả về kết quả thực.
- **inference (Vòng lặp ReAct):** Đây là bộ não xử lý lúc chạy thực tế. Nó thực hiện vòng lặp:
 1. Mô hình suy nghĩ và sinh văn bản.
 2. Nếu mô hình sinh ra thẻ <tool_call>, hệ thống sẽ dừng lại, gọi hàm invoke_tool.
 3. Kết quả từ tool được đưa ngược lại vào ngữ cảnh (context).
 4. Mô hình tiếp tục suy nghĩ dựa trên kết quả đó để đưa ra đáp án cuối cùng.
- **train:** Hàm này cấu hình và khởi chạy quá trình huấn luyện (Fine-tuning) sử dụng Trainer của Hugging Face.

3.1.6. Cấu hình Huấn luyện

- **Mô hình:** Sử dụng Qwen/Qwen2.5-Math-1.5B - một mô hình nhỏ gọn nhưng rất mạnh về toán học.
- **Tham số:** Sử dụng bfloat16 (BF16) để tiết kiệm bộ nhớ GPU, gradient_accumulation để tăng kích thước batch ảo, và các thiết lập tối ưu khác như gradient_checkpointing.

3.2. Huấn luyện, đánh giá và tối ưu mô hình (Model Training, Evaluation and Optimization)

Trong giai đoạn huấn luyện, nhóm tiến hành xây dựng hệ thống giải toán thông minh theo hướng Agentic AI, kết hợp linh hoạt giữa khả năng suy luận ngôn ngữ của Mô hình ngôn ngữ lớn (LLM) và độ chính xác của các công cụ tính toán bên ngoài (External Tools). Hệ thống được phát triển dựa trên nền tảng Qwen-2.5-Math-1.5B, áp dụng kỹ thuật tinh chỉnh có giám sát (Supervised Fine-Tuning - SFT) và cơ chế suy luận ReAct (Reasoning + Acting).

Mục tiêu chính là khắc phục hạn chế về "ảo giác" tính toán của các LLM truyền thống, đồng thời nâng cao khả năng giải toán tiếng Việt thông qua việc dạy mô hình biết cách "suy nghĩ" trước khi "hành động" gọi công cụ.

3.2.1. Quy trình tổng quan

Nhóm thiết lập quy trình huấn luyện đồng bộ sử dụng thư viện HuggingFace Transformers và TRL, bao gồm các bước chính:

1. **Chuẩn bị dữ liệu:** Dữ liệu sau khi tiền xử lý được chuyển đổi sang định dạng **Chat Template** chuẩn (System - User - Assistant).
 - *System Prompt:* Định hướng mô hình đóng vai trò là một trợ lý giải toán biết suy luận từng bước.
 - *User:* Câu hỏi toán học.
 - *Assistant:* Chuỗi suy luận (Chain-of-Thought) kèm theo các thẻ đặc biệt `<tool_call>` để gọi công cụ khi cần thiết.
2. **Cấu hình huấn luyện (Training Configuration):** Nhóm sử dụng lớp Config để quản lý tập trung các siêu tham số. Để tối ưu hóa tài nguyên GPU và tốc độ huấn luyện trên mô hình 1.5 tỷ tham số, nhóm áp dụng các kỹ thuật:
 - **Mixed Precision Training (BF16):** Sử dụng định dạng bfloat16 thay vì float32 để giảm bộ nhớ VRAM mà vẫn giữ được độ ổn định số học tốt hơn fp16.
 - **Gradient Accumulation:** Tích lũy gradient qua nhiều bước (32 steps) để mô phỏng batch size lớn hơn, giúp mô hình hội tụ tốt hơn trên phần cứng giới hạn.
 - **Gradient Checkpointing:** Giảm chi phí bộ nhớ bằng cách không lưu trữ tất cả các giá trị kích hoạt trung gian.
3. **Khởi tạo Agent (ToolUseAgent):** Xây dựng lớp ToolUseAgent để đóng gói logic của mô hình, bao gồm vòng lặp suy luận (Inference Loop), cơ chế gọi hàm (invoke_tool) cho Calculator và WikipediaRetriever, và tích hợp quy trình huấn luyện SFT.

3.2.2. Các phương pháp tiếp cận mô hình

Để đánh giá hiệu quả của giải pháp, nhóm đã triển khai và so sánh ba hướng tiếp cận khác nhau:

1. **Mô hình Llama 3.2 1B (Baseline):** Sử dụng mô hình ngôn ngữ đa dụng kích thước nhỏ làm cơ sở so sánh. Mô hình này được đánh giá khả năng giải toán trực tiếp (Zero-shot) hoặc Few-shot mà không qua tinh chỉnh chuyên sâu về toán học.
2. **Mô hình Qwen 2.5 Math (CoT):** Đây là mô hình được tinh chỉnh (Fine-tune) trên tập dữ liệu gốc (395k mẫu) để tăng cường khả năng suy luận chuỗi (Chain-of-Thought - CoT). Mô hình này tập trung vào việc sinh ra các bước giải logic bằng ngôn ngữ tự nhiên nhưng **không** sử dụng công cụ hỗ trợ. Mục tiêu là đánh giá khả năng nội tại của mô hình trong việc giải toán.
3. **Mô hình Qwen Agent (Tools - Đề xuất):** Đây là mô hình trọng tâm của đề án. Nhóm thực hiện Fine-tuning mô hình Qwen 2.5 trên tập dữ liệu giả lập "Reasoning-Action".

Mô hình học được cách nhận diện các phép tính phức tạp, sinh ra cú pháp gọi các công cụ, và sử dụng kết quả trả về để đưa ra đáp án cuối cùng.

3.2.3. Đánh giá mô hình

Khác với các bài toán phân loại thông thường, việc đánh giá hệ thống giải toán đòi hỏi các độ đo chuyên biệt để kiểm tra cả độ chính xác của đáp án và chất lượng của quá trình suy luận. Nhóm sử dụng bộ 3 chỉ số:

- **Exact Match:** Đo lường mức độ trùng khớp tuyệt đối giữa đáp án của mô hình và đáp án chuẩn (Ground Truth).
- **Numerical Accuracy:** Đo lường độ chính xác của giá trị số cuối cùng, chấp nhận các sai số nhỏ do làm tròn hoặc định dạng.
- **Reasoning Rate:** Tỷ lệ phần trăm các câu trả lời mà mô hình có thực hiện các bước suy luận (hoặc gọi tool) trước khi đưa ra kết quả, thay vì chỉ đoán mò đáp án.

4. Thực nghiệm

4.1. Phân chia tập dữ liệu

Tập dữ liệu sau khi tiền xử lý và sinh giả lập (Synthetic Data) được phân chia ngẫu nhiên thành hai tập con để đảm bảo tính khách quan trong quá trình đánh giá:

- Tập huấn luyện (Training set - 80%)
- Tập kiểm thử (Evaluation set - 20%)

4.2. Kết quả đánh giá

Hiệu suất mô hình được đo lường bằng 3 chỉ số: **Exact Match**, **Numerical Accuracy**, và **Reasoning Rate**.

Mô hình / Phương pháp	Exact Match	Numerical Accuracy	Reasoning Rate
Llama 3.2 1B	0.637	0.715	0.863

Qwen 2.5 1.5B (CoT)	0.743	0.801	0.804
Qwen Agent	0.532	0.711	0.546

Bảng 1.1: Kết quả thực nghiệm

Nhận xét:

- **Llama 3.2 1B:** Có *Reasoning Rate* cao nhất (0.863) nhưng độ chính xác thấp. Điều này phản ánh hiện tượng "ảo giác suy luận": mô hình sinh ra các bước giải rất dài dòng và có vẻ logic, nhưng nội dung toán học bên trong thường sai.
- **Qwen 2.5 (CoT):** Đạt hiệu suất cao nhất (Numerical Accuracy 0.801). Điều này chứng minh rằng việc Fine-tuning chuyên sâu vào khả năng suy luận nội tại trên dữ liệu chất lượng cao là phương pháp rất mạnh mẽ.
- **Qwen Agent:** Đạt độ chính xác số học 0.711. Mặc dù thấp hơn CoT, nhưng kết quả này chứng minh mô hình đã học được cách sử dụng công cụ.

4.3. Phân tích

4.3.1 Tại sao mô hình Llama 3.2 1B có Reasoning Rate cao nhất nhưng lại có Exact Match và Numerical Accuracy thấp hơn mô hình Qwen 2.5 1.5B (CoT)

Sự chênh lệch nghịch lý giữa **Reasoning Rate cao** nhưng **Độ chính xác thấp** của Llama 3.2 1B phản ánh hiện tượng '**Hallucination in Reasoning**'.

Chỉ số Reasoning Rate cao cho thấy Llama 3.2 rất tuân thủ định dạng, luôn cố gắng sinh ra các bước giải chi tiết. Tuy nhiên, do là mô hình đa dụng kích thước nhỏ và thiếu dữ liệu huấn luyện chuyên sâu về toán học, các bước suy luận của Llama thường mắc lỗi logic hoặc sai số tính toán.


Ngược lại, Qwen Math tuy có Reasoning Rate thấp hơn, nhưng nhờ được pre-train trên dữ liệu toán học, chất lượng của chuỗi suy luận cao hơn hẳn, dẫn đến kết quả đầu ra chính xác vượt trội. Điều này khẳng định rằng đối với bài toán chuyên biệt như Toán học.

4.3.2 Tại sao mô hình Qwen Agent không cho ra kết quả tốt hơn Qwen 2.5 1.5B (CoT)

Nhóm xác định nguyên nhân đến từ "**Complexity Cost**":

- Mô hình CoT chỉ cần làm một việc: Suy luận.
- Mô hình Agent phải làm hai việc: (1) Suy luận & (2) Ra quyết định chọn công cụ. Sai số trong bước ra quyết định (ví dụ: gọi tool khi không cần thiết, hoặc cú pháp gọi tool bị sai) sẽ ảnh hưởng dây chuyền đến kết quả cuối cùng. Ngoài ra, dữ liệu huấn luyện cho Agent là dữ liệu giả lập (synthetic), có thể chứa nhiều so với dữ liệu thực (ground truth) dùng cho CoT.

4.4 Demo



Hình 1.6: Demo

5. Tham khảo

<https://arxiv.org/abs/2502.05867>

<https://github.com/OwenLM/Owen2.5-Math>

<https://huggingface.co/meta-llama/Llama-3.2-1B-Instruct>

<https://arxiv.org/abs/2210.03629>

<https://arxiv.org/pdf/2303.09014>

<https://arxiv.org/pdf/2309.12284>

<https://arxiv.org/abs/2201.11903>